

Prediction of Photovoltaic Power Generation Based on LSTM Considering Daylight and Solar Radiation Data

일조 시간과 일조량 데이터를 고려한 LSTM 기반 태양광 발전량 예측

Yeon-Ju An · Taeck-Kie Lee · Kyu-Ho Kim

안연주* · 이택기** · 김규호†

Abstract

This paper presents a method to predict the photovoltaic power generation using daylight and solar radiation data. Keras based long short-term memory(LSTM) model, a deep learning library, is used to predict the photovoltaic power generation and compared with a simple machine learning model. Based on the annual power generation, the weather parameters are selected with the highest correlation such as sunshine time and solar radiation. The prediction of Keras based LSTM model is superior to the prediction of the photovoltaic power generation using the simple machine learning model. This is because the probabilistic characteristics of actual variables are considered forecasting with actual weather parameters in the prediction of photovoltaic power generation.

Key Words

Photovoltaic Power Generation, Prediction, Long Short-Term Memory(LSTM), Deep Learning

1. 서론

전 세계적으로 신재생 에너지원의 사용을 확대하고자 하는 기술적, 사회적 노력이 이루어지고 있다. 대한민국에서도 2017년 12월에 ‘재생에너지 3020 이행계획’을 발표하는 등 국내에서 신재생 에너지원의 발전용량이 기록적으로 늘어나는 추세이다. 그러나 신재생 에너지원은 기상 매개 변수들에 매우 민감하다는 확률적 특성이 있다. 따라서 전력 공급의 안정과 신뢰성을 유지하기 위해서는 발전량 예측에 관한 연구는 필수적인 것이다. 신재생 에너지의 발전량 예측에는 머신러닝(Machine learning)과 딥러닝(Deep learning) 기술로 예측을 수행하는 방법들이 연구에 주로 사용되며 그중에서도 인공신경망 기술을 활용한 연구가 큰 비중을 차지하고 있다. 신재생 에너지의 발전량 예측 효율을 높이려는 연구가 활발히 진행 중이다. Hui He 등은 조도 지수 및 LSTM을 기반으로 태양광 발전소의 전력 예측 접근 방식을 제시하였고[2], Spyros Theocharides 등은 인공신경망(Artificial Neural Network, ANN), 지원 벡터 회귀(Support Vector Regression, SVR)를 사용하여 비교하였다[3], 그리고 심층신경망(Deep Neural Network, DNN)을 활용하여 태양광 발전량 예측 모델을 구성하는 등의 연구가 이루어지고 있다[4].

본 논문에서는 태양광 발전 예측을 위하여 주요한 기상 매개 변수를 선정하여 실제 기상 데이터 세트를 활용하여 태양광 발전 예측하였다. 딥러닝 라이브러리 케라스(Keras)를 기반으로 신재생 에너지원의 하나인 태양광 발전기의 출력 예측 모델을 구성하여 학습 능력을 입증하고 발전량을 예측하였다.

2. 본론

2.1 딥러닝 모델링

시계열 분석을 통해서 태양광 발전량 및 일조 시간, 일사량의 데이터를 분석하고 딥러닝 라이브러리인 케라스를 사용하여 LSTM(Long Short-Term Memory) 모델을 구성하였다.

2.1.1 시계열 분석

시계열 분석은 일정한 시간 간격으로 시간 변수의 흐름에 따라 과거의 데이터에서 유의미한 법칙성을 학습하고 그 법칙성에 따라 반복되는 것을 가정하여 종속변수를 예측하는 것이다. 시계열 분석은 자료의 자기종속 구조를 파악하고 알아낸 구조와 법칙성으로 학습하는 모형(Model)을 개발하여 미래의

† Corresponding Author: Dept. of Electrical Engineering, Hankyong National University, Korea. IT Fusion Research Institute, Korea.

E-mail: kyuho@hknu.ac.kr
<https://orcid.org/0000-0003-0904-1733>

* Dept. of IoT Fusion Industry, Hankyong National University, Korea.
<https://orcid.org/0000-0002-2024-5107>

** Dept. of Electrical Engineering, Hankyong National University, Korea.
<https://orcid.org/0000-0003-2046-5932>

Received : Jul. 1, 2021 Revised : Jul. 27, 2021 Accepted : Jul. 28, 2021

Copyright © The Korean Institute of Electrical Engineers

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/4.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

값이나 상황을 예측하는 것을 목적으로 한다.

분석에 사용되는 시계열 자료의 특성으로는 추세 변동(Trend variation : T), 순환 변동(Cyclical variation : C), 계절 변동(Seasonal variation : S), 불규칙 변동(Irregular variation : I)이 있다. 실제로 관측되는 시계열 데이터는 위의 네 가지 요소가 합이나 곱의 형태로 결합한다고 가정하여 나타낸다.

2.1.2 케라스(Keras)

케라스(Keras)는 딥러닝 모델을 만들 수 있는 라이브러리이다. 케라스에서 가장 핵심적인 것은 모델이다. 딥러닝 모델을 생성할 때 우리는 다중 입력과 다중 출력 등의 복잡한 구성을 가진 모델을 필요로 하게 되는데 시퀀스 모델(Sequential model)로 순차적으로 레이어(Layer)를 쌓는 것 외에도 케라스 함수 API(Functional API)를 사용하여 복잡한 모델을 구성할 수 있다.

케라스로 딥러닝 모델을 만들려면 먼저 사용하고자 하는 원본 데이터를 불러오거나 시뮬레이션을 통해서 필요한 데이터를 생성한다. 이때 시뮬레이션에 사용할 데이터의 훈련셋, 검증셋, 시험셋을 생성한다. 그리고 사용하고자 하는 모델에 따라 시퀀스 모델과 케라스 함수 API 중에서 선택하여 필요한 레이어를 구성한다. 구성한 모델의 학습 과정을 설정하고 처음에 생성한 훈련셋을 이용하여 학습시킨다. 학습 과정을 반복하며 반복 횟수에 따라서 손실과 정확도 등을 보면서 학습 상황을 판단한다. 그다음 시험 셋으로 예측이 제대로 수행되었는지 모델을 평가한다.

2.1.3 LSTM(Long Short-Term Memory)

딥러닝 알고리즘의 방법의 하나인 RNN(Recurrent Neural Networks)은 직전의 데이터와 현재의 데이터를 취합하여 예측하는 구조이다. 시간상으로 순서를 갖는 입력값의 자기종속 구조를 분석할 수 있어 시간순서의 시계열 데이터를 처리하는데 적합하게 설계되어 있다. 이전의 데이터를 기억하고 현재의 데이터와 상관관계를 분석하여 다음 데이터를 예측하는 문제에서 유용하지만 보다 이전의 데이터를 고려할수록 경사를 소실하는 장기 의존성 문제를 가진다. 직전이 아닌 먼 과거의 데이터를 고려하지 못하는 한계점 때문에 이를 구조적으로 개선한 것이 LSTM이다.

LSTM은 그림 1과 그림 2에 나타난 것처럼 단일 뉴럴 네트워크이지만 내부에서 4개의 레이어가 상호작용하는 구조로 이루어져 있다. 그림 1은 기본 LSTM의 내부 구조를 보여주고 있다. 그림 2는 여러개의 층으로 이루어진 기본적인 LSTM의 구조이다. LSTM 네트워크의 내부 구조는 망각 게이트(Forget Gate), 입력 게이트(Input Gate), 출력 게이트(Output Gate)의 세 가지 게이트가 있으며 각 게이트에서 시그모이드 함수를 이용하여 정보를 선택적으로 처리하는 연산을 한다. 먼저 망각 게이트에서는 이전 데이터에서 어떤 값을 버리고 취할지를 결정한다. 이때 쓰이는 함수는 식 (1)과 같다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

h_t : t번째 은닉 상태

x_t : 시간 t에서 입력

입력 게이트에서는 현재의 정보를 셀 스테이트(Cell State)에 얼마나 더할지 결정한다. i_t 가 입력 게이트 역할을 해주며 \tilde{C}_t 의 값이 현재의 셀 스테이트 값이 된다.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (3)$$

망각 게이트와 입력 게이트를 통해서 얻은 결과값으로 현재의 셀 스테이트의 값을 새로 업데이트한다.

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$

C_t : t번째 셀 상태

마지막으로 출력 게이트는 위의 과정으로 정해진 셀 스테이트의 값을 최종적으로 얼마나 출력할지 결정한다.

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t * \tanh(C_t) \quad (6)$$




그림 1 LSTM 내부 구조

Fig. 1 LSTM Internal Structure




그림 2 LSTM 구조

Fig. 2 LSTM Structure

3. 시뮬레이션

본 연구에서는 신재생 에너지원 중 가장 큰 비중을 차지하는 태양광을 기반으로 한 발전기의 발전량을 예측하고자 한

다. 먼저 대상 지역의 연간 발전량을 통해 기상 매개 변수의 연관성을 찾아 관련 변수를 선정한다. 실제 기상 데이터 세트와 시간별 발전량 데이터 세트를 활용하여 선정한 기상 매개 변수로 대상 지역의 태양광 발전량을 예측해보고 발전량을 포함한 예측을 수행하여 선정한 매개 변수와의 연관성과 구성한 모델의 학습 능력 및 예측 성능을 확인한다. 전라남도 영암 지역의 대규모 태양광 발전소의 2019년도의 일조 시간과 일사량, 발전량 데이터를 이용하여 본 연구를 수행하였다. 발전량 데이터는 한국서부발전의 시간별 태양광 발전 현황 데이터를 수집하여 사용하였다. 일조, 일사 데이터는 기상청자료 개방포털에서 대상 지역의 데이터를 수집하였다.

3.1 기상 매개 변수 선정

3.1.1 계절별 발전량

영암군에 설치된 태양광 발전소의 2017년도부터 2019년도까지의 일별, 시간별 발전량 자료를 수집하였다. 전남 영암군 F1 경기장에 설치된 태양광 발전기의 총 설비용량은 13.3MW이며 그림 3은 2018년도 영암 태양광 발전기의 일간 발전량을 나타낸 것이다. 표 1은 그림 3의 데이터들을 계절별로 평균 내어서 발전량을 표시해 놓은 것으로 여름의 12~14시경 발전량이 가장 많고 겨울의 16~18시경의 발전량이 가장 적다.




그림 3 연간 영암 지역 태양광 발전량(2018년)

Fig. 3 Yearly Yeongam Photovoltaic Power Generation(2018)

표 1. 계절별 평균 태양광 발전량

Table 1 Average Photovoltaic Power Generation by Season

계절	발전량(kW)
봄	54,607,930
여름	59,298,574
가을	47,734,576
겨울	35,100,480

3.1.2 일조 시간 및 일사량

일반적으로 기준에 쓰이는 태양광 발전량 예측 방법에서 쓰이는 식 두 가지가 있다. 첫 번째 식은 연간 총발전량과 월평균 일사량, 연간 총 일사량의 데이터를 이용하였으며 식 (7)과 같다.

$$E_M = \frac{E_Y}{I_Y} \times I_M \quad (7)$$

E_M : 월별발전량 예측값(kWh/월)

I_M : 예측하고자하는 월의 평균일사량 예측값(MJ/m²/월)

I_Y : 과거의 연간 총 일사량(MJ/m²/월)

E_Y : 과거의 연간 총 발전량(kWh/년)

두 번째는 태양광 설비용량과 가동율, 월평균 일조 시간을 이용하며 식 (8)과 같다.

$$E_M = P \times SD_M \times \eta \quad (8)$$

P : 태양광 발전 설비용량(kW)

η : 가동율

SD_M : 예측하고자 하는 월의 일조 시간(h/월)

식 (7)과 식 (8)은 태양광 발전의 연간 발전량과 월간 발전량을 예측하는 데 주로 사용되며 두 식에서 고려하는 기상 매개 변수는 각각 일사량과 일조 시간이다. 그림 4와 5는 영암 지역의 연간 태양광 발전기의 일조 시간과 일사량을 나타낸 것이다. 계절별 발전량을 분석하였을 때 태양광 발전기의 발전량은 태양의 빛 에너지를 이용하여 발전하는 태양광 발전의 특성상 여름에 가장 많고 겨울에 가장 적은 것을 확인할 수 있다. 해당 연도의 일조 시간, 일사량, 평균 기온, 구름 등 여러 기상 매개 변수를 비교해보았을 때 두 계절에 가장 큰 차이를 보이는 것은 일조 시간과 일사량이었다. 일조 시간과 일사량은 두 매개 변수의 변화 추이가 비슷하며 발전량의 변화 추이와도 밀접하게 관련 있다고 판단하여 일조 시간과 일사량을 유의미한 기상 매개 변수로 선정하였다.




그림 4 전체 일조 시간

Fig. 4 Total Sunshine Time




그림 5 영암 지역의 태양광 발전 일사량

Fig. 5 Yearly Yeongam Photovoltaic Power Generation

3.2 딥러닝 모델을 이용한 예측

3.2.1 일조 시간과 일사량을 고려한 예측

시뮬레이션은 태양광 발전에 영향을 미치는 유의미한 기상 매개 변수로 일조 시간과 일사량을 선정하였다. 일조 시간과 일사량만으로 태양광 발전기의 발전량을 예측하였다. 그림 6은 예측에 사용할 일조 시간과 태양광 데이터를 가져온 발전기의 실제 발전량 그래프이다.

먼저 입력 데이터 요소들의 단위와 크기가 다르므로 요소들을 정규화한다. 각 데이터는 min-max scaler를 사용하여 정규화를 하였다. 정규화에 사용한 Min-Max 식은 아래와 같다. 이때 식 (9)는 각 요소의 최소값은 x_{\min} 에 최대값은 x_{\max} 에 대응시키는 함수이다.

$$x_{scaled} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (9)$$

x_{scaled} : 정규화 된 데이터

x : 대상 데이터

x_{\min} : 변수 x 의 최소값

x_{\max} : 변수 x 의 최대값




그림 6 태양광 발전량 데이터
Fig. 6 Photovoltaic Power Generation Data

일조 시간과 일사량을 입력으로 한 2가지 속성의 입력 모델이 학습한 결과는 그림 7에 나타내었다. 데이터 프레임에서 주황색 그래프는 2019년 6월 30일까지 각 날짜의 0시부터 24시까지의 일조 시간과 일사량의 데이터로 학습한 데이터이다. 훈련된 데이터로 예측을 수행한 결과는 초록색 그래프로 나타내고 있다. 그림 7의 파란색 그래프는 입력 데이터와 동일한 범위의 실제 시간별 태양광 발전량을 나타내는 그래프이다.




그림 7 일조 시간, 일사량을 고려한 예측

Fig. 7 Prediction considering Daylight Time and Solar Radiation

결과는 학습된 데이터로 예측을 수행한 그래프가 실제 발전량을 나타내는 파란색 그래프의 영역에서 조금씩 벗어나는 모습을 확인할 수 있다. 일조 시간과 일사량만으로 예측을 수행한 그래프가 실제 발전량에 못 미치거나 넘어가는 경우는 과거 데이터로 학습하여 예측한 것과 실제 기상 상황의 차이가 발생된 것의 영향이라고 분석된다. 그림 8은 실측값과 예측값의 오차를 보여주는 그래프이다. 이 경우에 epoch가 많을수록 손실이 작아짐을 알 수 있다.




그림 8 일조 시간, 일사량 모델을 고려한 손실

Fig. 8 Loss considering Daylight and Solar Radiation Model

3.2.2 일조 시간, 일사량 및 발전량을 고려한 예측

그림 9는 두 가지의 기상 매개 변수에 실제 발전량까지 입력 데이터로 넣어서 예측을 수행한 결과이다. 그림 9는 실제 발전량 데이터의 그래프를 벗어나는 값들이 그림 7에 비해서 적게 확인된다. 오차는 확연히 줄어들어 예측의 정확도가 높아졌다. 그러나 실제 발전량 데이터를 입력했음에도 예측을 수행한 그래프가 실제 발전량 그래프와 차이를 보인다는 것은 본 논문에서 고려한 기상 매개 변수들 외에 다른 매개 변수들도 작용한 결과라고 볼 수 있다. 그러나 그림 7의 결과와 그림 9는 매우 유사한 추이를 보이고 있으며 일조 시간과 일사




그림 9 일조 시간, 일사량 및 발전량을 고려한 예측

Fig. 9 Prediction considering Daylight Time, Solar Radiation and Power Generation




그림 10 일조 시간, 일사량, 발전량 모델을 고려한 손실

Fig. 10 Loss considering Daylight Time, Solar Radiation and Power Generation Model

량이 실제 태양광 발전에 유의미한 기상 매개 변수임을 확인할 수 있었다. 또한, 그림 10은 실측값과 예측값의 오차율을 보여주는 그래프이다. 이 경우에 epoch가 많을수록 손실이 작아짐을 알 수 있다.

3.3 머신러닝과 딥러닝 예측 결과의 비교

머신러닝의 예측 결과를 통해 딥러닝이 태양광 예측을 수행하는데 더욱 적합함을 확인하였다. 그림 11은 동일한 일자의 발전량 데이터를 활용하여 예측을 수행한 머신러닝 모델의 태양광 발전량 예측 결과이다.




그림 11 머신러닝에 의한 태양광 발전 예측

Fig. 11 Prediction of Photovoltaic Power Generation in Machine Learning Model




그림 12 머신러닝에 의한 태양광 발전 예측(2017~2019년)

Fig. 12 Prediction of Photovoltaic Power Generation in Machine Learning Model

(2017~2019)

간단한 머신러닝 모델의 예측 결과를 보면 딥러닝 모델의 예측 결과에 비해서 부정확하게 예측한 것을 알 수 있다. 딥러닝의 예측 결과는 그림 6의 태양광 발전량 데이터의 그래프와 매우 유사한 것을 확인할 수 있는 것에 비해, 머신러닝 모델을 이용한 태양광 발전량 예측 결과는 현저히 떨어지는 예측 정확도와 그 결과를 확인할 수 있다.

그 오차의 가장 큰 원인으로는 신재생 에너지원 발전량 예측에 중요한 기상 매개 변수를 한 가지도 고려하지 않은 상태로 오로지 발전량 데이터로만 학습을 시켜서 예측을 수행한 것이다. 그리고 또 다른 원인으로는 데이터의 양이다. 딥러닝 모델과 동일한 데이터로 예측을 수행하였지만, 데이터의 양이 예측이 부정확한 것의 원인으로 꼽히는 것은 그림 12로부터 알 수 있다.

그림 12의 그래프는 동일한 지역의 2017년 1월 1일부터 2019년 6월 30일까지의 태양광 발전량 데이터이며, 시간별 데이터를 합산한 일별 발전량 데이터를 이용하여 모델을 훈련 시킨 것이다. 동일한 머신러닝 모델로 많은 양의 데이터를 이용하여 학습을 시키고 예측을 수행한 결과는 앞선 결과보다 좋은 결과를 보여주고 있다. 예측의 결과에서 예측 그래프가 실제 값의 그래프와 차이가 나는 것을 확인할 수 있다. 그러나 실제 값의 그래프와 예측 그래프는 변동 추이가 매우 유사함을 알 수 있다. 그림 11과 그림 12에 나타난 결과들로부터 많지 않은 데이터로 정확도가 높은 딥러닝 모델을 사용하여 태양광 발전량 예측을 수행하는 것이 머신러닝 모델을 사용하는 것보다 적합함을 알 수 있다.

4. 결론

본 논문에서는 태양광 발전량 예측하기 위하여 딥러닝 라이브러리인 케라스 기반의 LSTM 모델을 사용하였으며 간단한 머신러닝 모델과 비교하였다. 실제 기상 데이터는 연간 발전량을 토대로 가장 연관성이 높은 기상 매개 변수인 실제 일조 시간과 일사량을 선정하였다.

케라스 기반의 LSTM 모델은 머신러닝 모델을 이용한 태양광 발전량 예측 결과보다 우수하였으며, 이것은 태양광 발전량을 예측하는 데 있어서 실제 기상 매개 변수로 예측하였을 때 실제 변수들의 확률적 특성이 고려되었기 때문이다. 향후 일조 시간 및 일사량 외에 다양한 기상 매개 변수를 고려하여 태양광 발전량 예측의 정확도를 높일 필요가 있다고 사료된다.

Acknowledgements

“이 논문은 한경대학교 전력시스템 연구실 지원으로 수행되었음”

References

- [1] D. Su, E. Batzelis, B. Pal, “Machine Learning Algorithms

in Forecasting of Photovoltaic Power Generation,” International Conference on Smart Energy Systems and Technologies (SEST), 2019.

- [2] H. He, R. Hu, Y. Zhang, Y. Zhang, R. Jiao, “A Power Forecasting Approach for PV Plant based on Irradiance Index and LSTM,” 37th Chinese Control Conference (CCC), 2018.
- [3] S. Theocharides, G. Makrides, G. E. Georghiou, Andreas. Kyprianou, “Machine learning algorithms for photovoltaic system power output prediction,” IEEE International Energy Conference (ENERGYCON), 2018.
- [4] S. Y. Park, J. H. Bang, I. H. Ryu, and T. H. Kim, “The Prediction of Photovoltaic Power Using Regression Models Based on Weather Big-data and Sensing Data,” Trans. of KIEE, vol. 68, no. 12, pp. 1662-1668, 2019.
- [5] A. Golder, J. Jneid, J. Zhao, F. Bouffard, “Machine Learning-Based Demand and PV Power Forecasts,” IEEE Electrical Power and Energy Conference (EPEC), 2019.
- [6] Y. Yu, J. Cao, J. Zhu, “An LSTM Short-Term Solar Irradiance Forecasting Under Complicated Weather Conditions,” IEEE Access, vol. 7, 145651-145666, 2019.
- [7] J. Y. Choi, S. G. Lee, “Short-term wind power forecast using hourly LSTM technique,” Trans. of KIEE, vol. 69, no. 6, pp. 759-764, 2020.
- [8] S. Hochreiter, J. Schmidhuber, “Long Short-Term memory,” Neural Computation, vol. 9, no. 8, pp. 1735-1780, 1997.
- [9] J. Y. Kim, B. M. Kim, H. J. Bang and M. S. Jang, “A Proposal of the Prediction Method of Decentralized Power on Climatic Change,” Spring 2010, KIMICS Integrated Conference, pp. 942-945, May 2010.
- [10] I. R. Lee, I. S. Bae, J. O. Kim and H. Shim, “Photovoltaic System Output Forecasting by Solar Cell Conversion Efficiency Revision Factors,” Trans. of KIEE, vol. 54, no. 4, pp. 188-194, 2005.
- [11] W. S. Ju, M. S. Jang, Y. S. Lee, S. C. Bae and W. G. Kim, “Suggestion of a Hybrid Method for Estimating Photovoltaic Power Generation,” Fall 2011, KIMICS Integrated Conference, pp. 782-785, Oct. 2011.



이택기 (Taeck-Kie Lee)

1987년 한양대 전기공학과 졸업. 1989년 동 대학원 전기공학과 졸업(석사). 1993년 동 대학원 전기공학과 졸업(공학박). 1994년 3월~1996년 8월 서남대학교 전기공학과 전임강사. 2010년 2월~2011년 1월 성균관대학교 연구교수. 2018년 2월~2019년 1월 University of Colorado Denver Visiting Scholar. 1996년 9월~현재 한경대학교 전자전기공학부 교수.



김규호 (Kyu-Ho Kim)

1988년 한양대 전기공학과 졸업. 1990년 동 대학원 전기공학과 졸업(석사). 1996년 동 대학원 전기공학과 졸업(공학박). 1996년 3월~2008년 8월 신안산대학 전기과 부교수. 2011년 9월~2012년 8월 Baylor University Visiting Scholar. 2020년 2월~2021년 1월 University of Colorado Denver Visiting Scholar. 2008년 9월~현재 한경대학교 전자전기공학부 교수.

저자소개



안연주 (Yeon-Ju An)

2019년 2월 한경대학교 전자전기공학과 졸업. 2021년 2월 한경대학교 일반대학원 IoT 융합산업학과 졸업(석사).